

# DeepLesion: automated mining of large-scale lesion annotations and universal lesion detection with deep learning

<http://yanke23.com/articles/research/2018/06/13/DeepLesion-dataset-CVPR-2018.html>

소스 : [https://github.com/rsummers11/CADLab/tree/master/lesion\\_detector\\_3DCE](https://github.com/rsummers11/CADLab/tree/master/lesion_detector_3DCE)



# Abstract

- ▶ 대규모의 병변 이미지 데이터셋을 만들기 위해서 많고 주석이 달린 의료 데이터를 수집하는 것을 제안
- ▶ 이 과정은 많은 수작업이 필요
- ▶ DeepLesion 을 개발하여 북마크( 주석 )를 작성함
- ▶ DeepLesion을 사용하여 하나의 통일 된 프레임 워크로 모든 유형의 병변을 찾을 수있는 보편적 인 병변 탐지기를 학습시킴.
- ▶ 병변 검출기는 이미지 당 5 개의 오탐률로 81.1 %의 감도를 달성


# 1. Introduction

- ▶ 기존 CAdE/CAdx 를 활용하여 병변을 탐색하였지만, 범용적이지 못함.
- ▶ 이논문에서는
  1. 최소한의 수작업으로 \*북마크로부터 병변 주석을 수집하는 패러다임을 소개
    - ▶ \* 북마크는 타겟 이미지 검색 결과를 강조하기 위해 매일 작업하는 동안 방사선과 의사가 표시 한 메타 데이터.
  2. faster R-CNN을 기반한 알고리즘을 사용해서 자동 병변 탐지 알고리즘을 개발함

## 2. Materials and Methods

### 2.1 Bookmarks

- ▶ 옆의 그림이 bookmarked 이미지
- ▶ response evaluation criteria in solid tumors (RECIST) 가이드에 따라서 표시되고, 암치료재의 임상평가에 중요한 지표임 => bookmark는 병변을 찾기 위한 중요한 표시자가 됨.
- ▶ 방사선과 의사들은 화살표, 선, 타원, 양축 **RECIST 지름**, 세그멘테이션 및 텍스트를 사용해서 bookmark를 표시
- ▶ RECIST-diameter는 장축 길이과 장축에 수직인 축의 길이로 구성





## 2.2 DeepLesion Dataset

- ▶ RECIST diameters 만을 고려해서 데이터 수집
- ▶ 2017년 1월까지 33,418 bookmarks 수집
- ▶ 아래 순서으로 데이터 설명
- ▶ setup procedure, data statistics, advantages, limitations, and potential applications


## 2.2.1 Setup procedure

- ▶ PACS 쿼리를 통해서 bookmark을 갖는 CT 연구의 accession번호를 획득.
- ▶ Bookmark데이터는 PACS에서 제공하는 perl 스크립트로 다운로드.
- ▶ 4 개의 정점으로 표현되는 RECIST 직경의 것들만을 선택
- ▶ 비축형 것들(nonaxial ones) 을 필터링한 다음 정점을 이미지 좌표로 변환
- ▶ 변환은 먼저 각 꼭지점에서 "ImagePositionPatient"(DICOM 파일에서 추출한)를 빼고 각 꼭지점의 좌표를 픽셀 간격으로 나누어 수행.
- ▶ MATLAB을 사용해서 각각의 이미지 slice을 DICOM files에서 PNG 로 변환
- ▶ 실제 환자번호는 1부터 시작하는 숫자로 치환
- ▶ "{patient index}\_{study index}\_{series index}" 이런 파일 포맷을 사용
- ▶ RECIST diameters -> 네개의 정점을 갖는 bounding-box로 변환, (x11, y11) ....
- ▶ Z 축은 생략
- ▶ 잘못된 bookmark는 많지 않았지만, 폭과높이의 비율을 구해서 이 평균과 분산과 많이 다른 것을 제거



## 2.2.2 Data statistics

- Slice의 간격 : 0.25 ~ 22.5 mm사이이고, 48.3%는 1mm, 48.9% 5mm
- 이미지 크기 : 대부분은 512x512, 0.12%는 768x768, 1024x1024
- Bounding-box : 폭은 22.9, 길이 22.3가 중앙값
- 9816 병변을 랜덤 선택
- 폐 (2426), 복부 (2166), 종격동 (mediastinum) (1638), 간 (1318), 골반 (869), 연조직 (677), 신장 (490), 뼈 (232)
- 대략적인 z 좌표를 얻기 위해서 slice score 을 예측하는 [unsupervised body part regressor](#)을 채택.



**Fig. 6** Distribution of the sizes of the bounding-boxes in DeepLesion. The bounding-boxes were computed from the RECIST diameters after dilation by 5 pixels. The width and height are the size of the x- and y-axes of the boxes, respectively.

K. Yan, L. Le, and R. M. Summers, “[Unsupervised body part regression](#) via spatially self-ordering convolutional neural networks,” in IEEE Int. Conf. on Biomedical Imaging (ISBI 2018), pp. 1022–1025 (2018).



## 2.3 Universal Lesion Detection

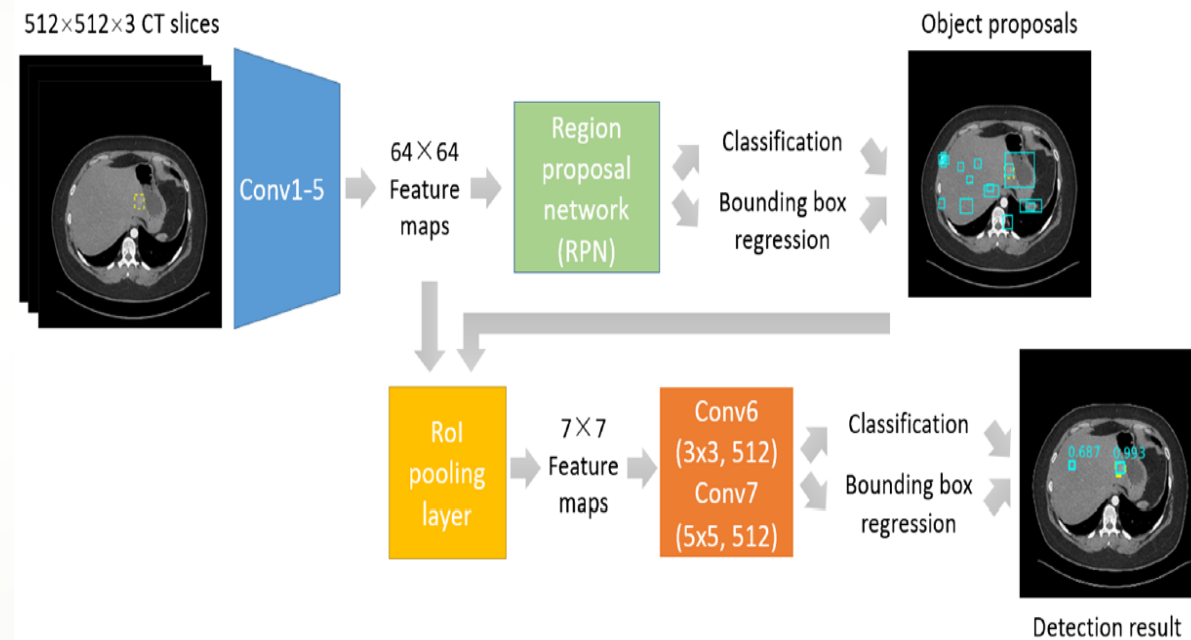
### 2.3.1 Image preprocessing

- ▶ 12-bit CT 이미지를 [0, 255]의 부동 소수점으로 재 조정.
- ▶ 512x512로 이미지 크기 조절
- ▶ 3차원 정보를 인코딩 하기 위해서 3개의 축 방향 slice를 사용하여 3채널 이미지를 조립하고 이를 네트워크에 입력
- ▶ Data augmentation은 하지 않음.



## 2.3.2 Network architecture

- ▶ VGG-16은 백본으로 하고, ResNet-50, DenseNet-121, AlexNet을 비교하여, VGG-16이 가장 좋은 성능.
- ▶ 그림 7 설명
- ▶ 이미지는 VGG-16 (Conv1-Conv5)에서 처음 처리되어 feature map을 생성, feature map의 해상도를 증진시키고 positive sample 비율을 늘리기 위해서 pooling layers (pool4, pool5)은 제거 <= 병변은 작고 sparse 하기 때문
- ▶ Region proposal network는 feature map을 파싱하고 병변 추천 지역을 제안해줌. => lesion/non-lesion 비율 계산, 병변의 위치와 크기를 fine-tuning => 5개 크기의 box( 16, 24, 32, 48, 96)와 3개의 비율 ( 1:2, 1:1, 2:1 )



**Fig. 7** Flowchart of the lesion detection algorithm. Yellow dashed and cyan solid boxes in each image indicate the ground-truth and the predicted bounding-boxes, respectively.

## 2.3.2 Network architecture


- ▶ RPN에서 제안된 lesion 과 VGG-16에서 추출된 feature maps은 RoI pooling layer에 합쳐져서 7x7 크기의 feature map를 재샘플링.
- ▶ Conv6 와 Conv7인 2개의 conv layer로 보내지고, 이것은 오리지널 VGG-16의 1/4 크기의 모델
- ▶ Conv6 :  $512\ 3 \times 3$  filters, zero padding , stride 1
- ▶ Conv7 :  $512\ 5 \times 5$  filters, zero padding , stride 1
- ▶ 이 2개의 conv layer뒤에 Rectified linear units 추가
- ▶ Conv7의 512차원 featurer값은 2개의 full-connected layer로 보냄 => 병변의 신뢰 스코어를 예측과 fine-tuning을 위한 bounding box 회귀분석을 실행
- ▶ 최종으로 예측하는 box을 fine-tuning을 위한 Nonmaximum suppression (NMS)을 적용하였고 스레드홀드값은 training 0.7, testing 0.3 임.

## 2.3.3 Implementation details

- ▶ MXNet 을 사용하여 구현
- ▶ ImageNet pretrained VGG-16 model을 Conv1~ conv5에 w의 초기값으로 줌.
- ▶ 다른 layer은 랜덤하게 초기값을 줌.
- ▶ Conv1과 Conv2는 가중치를 고정시켰고, 2개의 분류기와 2개의 regression losses가 연결되어서 최적화되도록 함. => original faster RCNN보다 효율적임.
- ▶ mini-batch는 8개의 이미지
- ▶ 이미지당 제안 가능한 병변의 수는 32개로 설정
- ▶ stochastic gradient descent ( SGD ) optimizer 적용
- ▶ 초기 학습율은 0.002, 6번의 epoch 마다 10배로 감소

### 3. Results

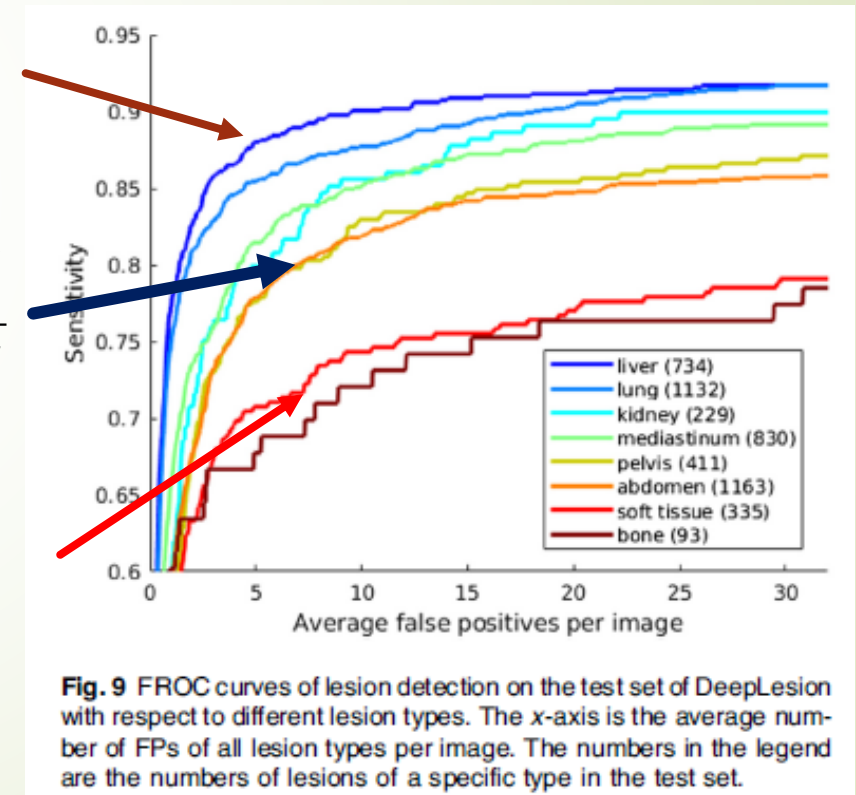
- ▶ training (70%), validation (15%), test (15%)으로 랜덤하게 나눔.
- ▶ Titan X GPU에서 생성된 모델로 하나의 테스트 이미지를 처리하는데 0.034초 소요.




상대적으로 배경  
과 구분됨.

창자와 장간막이  
어지럽고 유사한  
모양임.


연조직과 뼈는  
샘플수가 적고  
병변과 정상적  
인 조직이 구분  
이 어려움.



- ▶ 그림 10은 병변의 크기에 따른 FROC curve. 크기  $\leq$  장축과 단축의 평균값.
- ▶ 작은 크기의 병변이 탐지가 어렵고, 큰 크기의 병변이 탐지가 쉬움.
- ▶ 특이한 점은 10 ~ 50 mm사이의 병변은 크기에 비례하지 않음.
- ▶ 그림 11은 IoU threshold에 따른 탐지 정확도를 보여주고, threshold가 클수록 정확도는 떨어짐.



**Fig. 10** FROC curves of lesion detection on the test set of DeepLesion with respect to different lesion sizes. The x-axis is the average number of FPs of all sizes per image. The numbers in the legend are the numbers of lesions of a specific size in the test set. Accuracy can be affected by multiple factors, such as lesion size, lesion type, number of training samples, etc. Thus, its order does not strictly follow the order of lesion size.



**Fig. 11** Sensitivity of lesion detection on the test set of DeepLesion with respect to different IoU thresholds and the numbers of average FPs per image.





## 4 Discussion

### 4.1 DeepLesion Dataset

#### 4.1.1 Advantages

▶ 데이터셋안에는 중요한 방사선 검사 결과가 포함되어서

1) 범용 병변 탐지기를 개발할 수 있음.

방사선과 의사들에게 병변 탐지에 도움이 되고, 초기 스크리닝 도구로 활용 가능

2) 병변들의 다른 종류들간의 관계를 연구 가능

여러 연구 결과를 하나로 묶음. 분석결과에서 관계를 발견할 수 있고, 기존 도구의 정확도를 높일 수 있음. 이는 다른 데이터셋으로는 불가능

▶ 많은 데이터와 적은 주석화 노력

DeepLesion을 사용해서 최소의 노력으로 주석이 있는 데이터셋을 모을 수 있고 이미지넷과 같이 효율한 데이터 셋이 될 것을 기대함.

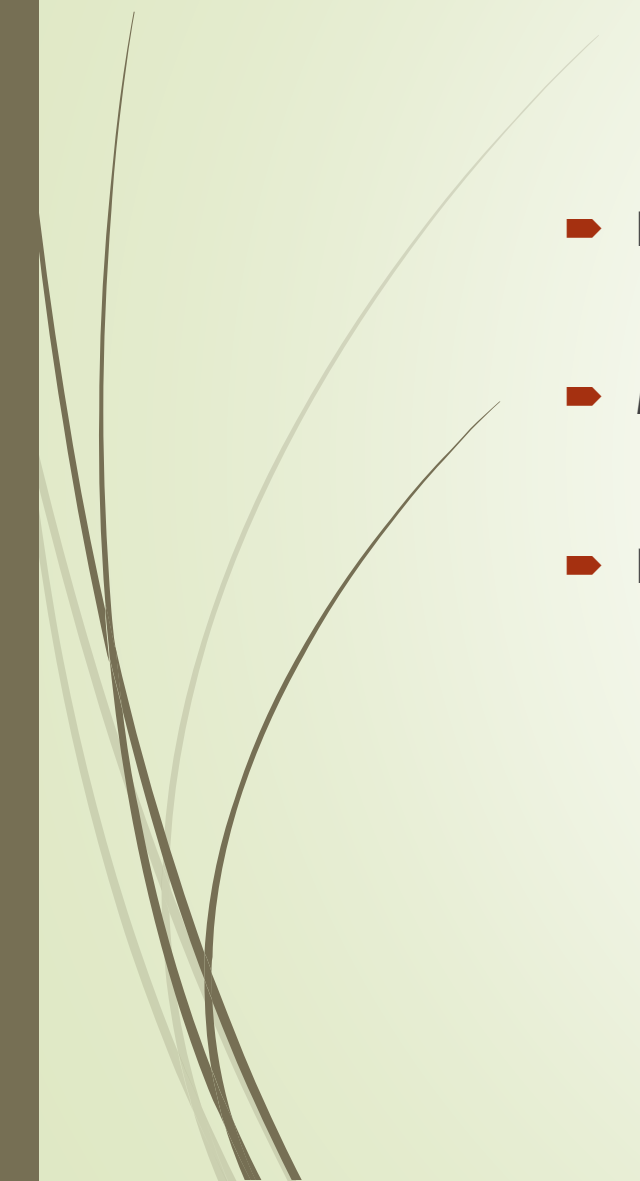


## 4.1.2 Potential applications

- Lesion detection : 진단에 핵심부분, 전문의에게 탐지 정확도를 높여주고 시간을 줄어줌.
- Lesion classification : 병변의 종류를 알아냄. 연구 리포트에 연결해서 자연 언어 처리 알고리즘을 사용하여 병변 유형 및 기타 정보 단서를 자동으로 추출할 수 있음.
- Lesion segmentation : 주석 처리 과정에서 사람의 부담을 줄어줌.
- Lesion retrieval : 텍스트 또는 이미지가 쿼리가 되어서 관련 병변을 찾을 수 있음.
- Lesion growth analysis : 병변의 모양과 기타 정보를 기반으로 병변의 변화를 분석하고 예측할 수 있음.



## 4.1.3 Limitations

- Lack of complete labels
  - Missing annotations
  - Noise in lesion annotations
- 

## 4.2 Universal Lesion Detection

- 방사선과 의사들은 대표적인 병변만 표시해서 테스트셋안에는 missing annotations이 포함됨. => 테스트셋안에는 FP 비율이 낮음.
- 이번 결과는 실재 정확도는 불완전하지만 합리적인 결과물이라고 주장할 수 있음.
- 다른 연구에서는 정교한 탐지 모델을 만들기 위해서 특정 병변만을 사용하였지만 이번 연구에서는 특정한 병변만은 사용하지 않음. => 더 범용적임.

## 5 Conclusion

- 병변 주석을 수집하고 수동으로 최소한의 노력으로 대규모 병변 데이터 세트를 작성하는 방법론은 소개함.
- 방사선과 의사들이 수작업으로 표시한 데이터 셋을 분석해서 DeepLesion 모델로 만듦.
- DeepLesion은 다양한 병변으로 구성되었고 여러 응용분야가 있음.
- 직접적인 응용분야는 하나의 프레임워크에서 다양한 종류의 병변을 찾을 수 있는 탐색기위 개발임.
- 더 많은 데이터를 수집하고 병변유형을 추출하여 DeepLesion 데이터 셋을 향상시킬 것이고 또한, 3차원 정보와 병변 종류 정보를 활용해서 병변 탐지기글 개선할 계획임.